

Material de Estudio I1

Minería de Datos (IIC-2433)

Maximiliano Ojeda

1 Selección Múltiple

Pregunta 1

¿Qué mide la Divergencia KL (Kullback-Leibler)?

- A) La distancia euclidiana promedio entre todos los pares de puntos de un dataset.
- B) El número óptimo de clusters que debiera tener un dataset dado.
- C) El grado de correlación lineal entre dos variables numéricas continuas.
- D) Cuánto se desvía una distribución de probabilidad respecto a otra distribución de referencia.

Pregunta 2

En PCA, los autovalores (λ) están ordenados de mayor a menor porque:

- A) Cada autovalor indica la varianza capturada por su componente, y se prioriza la de mayor varianza.
- B) Es una convención arbitraria sin relación con la varianza capturada por cada componente.
- C) Los autovalores negativos deben descartarse antes de continuar con el análisis.
- D) Así lo exige el algoritmo de clustering que se aplicará después de PCA.

Pregunta 3

En DBSCAN, un punto borde (border point) se caracteriza por:

- A) Tener al menos minPts vecinos dentro de su propio radio ϵ de vecindad.
- B) Estar dentro del radio ϵ de un núcleo, pero no cumplir minPts por sí mismo.
- C) Ser un punto que nunca queda asignado a ningún cluster formado.
- D) Corresponder siempre al centro geométrico calculado para cada cluster.

Pregunta 4

Explique por qué SNE original (con distribución Gaussiana en baja dimensión) sufre del “crowding problem”, y cómo la elección de la distribución t de Student con 1 grado de libertad en t-SNE lo mitiga.

- A) La Gaussiana de baja dimensión tiene colas muy pesadas, lo que empuja artificialmente a todos los puntos hacia el borde exterior del embedding, mientras que la t de Student concentra todo en el centro.
- B) En baja dimensión hay menos volumen disponible para puntos moderadamente distantes, comprimiéndolos con una Gaussiana. La t de Student, de colas más pesadas, les permite representarse más separados.
- C) El crowding problem se origina porque SNE nunca centra los datos antes de calcular las probabilidades condicionales, error que la t de Student corrige matemáticamente.
- D) La distribución t de Student reemplaza por completo el cálculo de la divergencia KL, evitando así la necesidad de comparar dos distribuciones de similitud.

Pregunta 5

¿Por qué K-NN se ve especialmente afectado por la maldición de la dimensionalidad?

- A) Porque en alta dimensión las distancias entre puntos se vuelven casi todas iguales, perdiendo poder discriminativo.
- B) Porque K-NN únicamente puede aplicarse a problemas de regresión, nunca de clasificación.
- C) Porque K-NN no permite calcular ninguna distancia entre observaciones del dataset.
- D) Porque K-NN exige que todos los atributos del dataset sean estrictamente categóricos.

Pregunta 6

Si se elige un valor de ϵ demasiado grande en DBSCAN, el resultado más probable es:

- A) Todos los puntos del dataset terminan siendo clasificados como ruido/outliers.
- B) El algoritmo DBSCAN deja de converger y no entrega ningún resultado.
- C) Se forman clusters muy amplios, fusionando grupos que debieran quedar separados.
- D) Se hace necesario recalcular minPts de forma completamente automática.

Pregunta 7

Explique por qué en DBSCAN dos clusters con densidades internas muy diferentes (uno muy denso y otro muy disperso) son difíciles de separar correctamente usando un único par de parámetros (ϵ , minPts) global.

- A) DBSCAN no presenta ninguna limitación relacionada con la densidad, por lo que separa perfectamente clusters de cualquier densidad interna.
- B) Un ϵ ajustado al cluster denso resulta demasiado pequeño para el disperso, y uno ajustado al disperso fusiona indebidamente el cluster denso.

- C) DBSCAN corrige automáticamente las diferencias de densidad entre clusters sin necesidad de ajustar manualmente ningún parámetro.
- D) El problema se resuelve simplemente aumentando el valor de minPts , sin modificar en ningún caso el valor de ε .

Pregunta 8

El método del codo (Elbow) se utiliza para:

- A) Elegir el número óptimo de vecinos que se usarán en K-NN.
- B) Elegir un valor razonable de k en K-Means observando la inercia.
- C) Calcular la similitud coseno entre dos vectores de atributos.
- D) Determinar el valor de perplejidad adecuado en un embedding t-SNE.

Pregunta 9

Una alta correlación de Pearson entre dos variables (ej. $r = 0.99$ entre “experience” y “salary” en el heatmap mostrado) es relevante para PCA porque:

- A) Señala redundancia entre variables, que PCA puede resumir en una sola componente.
- B) Obliga a eliminar ambas variables antes de poder aplicar PCA al dataset.
- C) Impide matemáticamente que PCA pueda ejecutarse sobre ese conjunto de datos.
- D) Aumenta de forma artificial la varianza total explicada por el dataset.

Pregunta 10

Al comparar el método del Elbow (basado en inercia) con el Silhouette Score para elegir k , ¿por qué el Elbow puede ser ambiguo cuando la curva de inercia decrece de forma suave sin un “codo” claro, mientras que Silhouette sigue siendo útil en ese escenario?

- A) Porque el Silhouette Score no depende en absoluto del valor de k elegido, a diferencia de la inercia usada en el método del codo.
- B) Porque el método del codo y el Silhouette Score siempre coinciden exactamente en el valor de k que recomiendan, sin excepción alguna en la práctica.
- C) Porque el Silhouette Score requiere contar con las etiquetas reales (ground truth), mientras que el método del codo no las necesita.
- D) Porque Silhouette acota y normaliza cohesión y separación por punto, permitiendo comparar k directamente, mientras la inercia decrece monótonamente sin límite fijo.

Pregunta 11

Si tras aplicar K-Means con varias inicializaciones aleatorias de centroides se obtienen resultados distintos (distintos clusters), esto se debe a que:

- A) K-Means es un algoritmo determinista, por lo que este comportamiento no debería ocurrir nunca.

- B) K-Means es sensible a la inicialización y puede converger a óptimos locales distintos.
- C) El dataset utilizado contiene necesariamente un error en su construcción.
- D) La distancia euclidiana no puede aplicarse a este tipo de dataset.

Pregunta 12

Si el Adjusted Rand Index (ARI) entre dos particiones de clustering es -0.05 , esto indica que:

- A) El clustering obtenido es incluso peor que una asignación aleatoria.
- B) Las dos particiones comparadas coinciden de manera prácticamente perfecta.
- C) El clustering obtenido es equivalente a una asignación completamente aleatoria.
- D) El valor de ARI obtenido no admite ningún tipo de interpretación.

Pregunta 13

¿Por qué K-Means tiene dificultades para separar correctamente los datos en forma de “lunas” (moons) o “círculos concéntricos” mostrados en las diapositivas comparativas con DBSCAN?

- A) Porque K-Means no está diseñado para calcular distancias de tipo euclidiano.
- B) Porque K-Means solo puede ejecutarse correctamente con más de mil puntos.
- C) Porque K-Means únicamente funciona en problemas de una sola dimensión.
- D) Porque K-Means asume clusters esféricos y de tamaño similar, no formas no convexas.

Pregunta 14

Se tiene un dataset de alta dimensión con clusters de formas no convexas y densidades muy variables entre grupos. Justifique por qué aplicar K-Means directamente sobre los datos originales sería inadecuado, y proponga una alternativa más apropiada, explicando por qué.

- A) K-Means resulta siempre la mejor alternativa posible, incluso frente a formas de espiral y densidades heterogéneas entre grupos.
- B) K-Means asume clusters esféricos de densidad similar. HDBSCAN es más apropiado, pues no asume convexidad y se adapta a densidades heterogéneas.
- C) t-SNE debería usarse como algoritmo de clustering final, reemplazando por completo la necesidad de aplicar K-Means o HDBSCAN.
- D) Ninguno de los algoritmos de clustering revisados en el curso es capaz de manejar razonablemente este tipo de escenario.

Pregunta	Correcta
Pregunta 1	D
Pregunta 2	A
Pregunta 3	B
Pregunta 4	B
Pregunta 5	A
Pregunta 6	C
Pregunta 7	B
Pregunta 8	B
Pregunta 9	A
Pregunta 10	D
Pregunta 11	B
Pregunta 12	A
Pregunta 13	D
Pregunta 14	B

2 Preguntas de Desarrollo

Pregunta de Desarrollo 1

A continuación se presenta una lista desordenada de 9 posibles pasos para un pipeline de clustering. **5 de ellos son pasos correctos** de un pipeline metodológicamente válido, y **4 son pasos incorrectos** (distractores) que no deberían formar parte de dicho pipeline.

- A. Aplicar PCA antes de estandarizar los datos.
 - B. Estandarizar los datos (ej. `StandardScaler`).
 - C. Aplicar clustering (ej. K-Means) directamente sobre la proyección 2D de UMAP.
 - D. Aplicar PCA sobre los datos ya estandarizados, reteniendo un alto porcentaje de varianza (ej. 95%).
 - E. Elegir el k que entrega la menor inercia.
 - F. Aplicar clustering (ej. K-Means) sobre la representación de alta dimensión obtenida con PCA.
 - G. Elegir k mediante el método del codo y/o el Silhouette Score.
 - H. Aplicar t-SNE o UMAP sobre los datos ya clusterizados, usando esa proyección únicamente para visualización del resultado.
 - I. Reemplazar por completo el paso de clustering, usando solamente la proyección de t-SNE como resultado final del análisis.
- (a) Seleccione los 5 pasos correctos y ordénelos en la secuencia adecuada.
- (b) Para cada uno de los 4 pasos incorrectos, explique brevemente (1 línea) por qué no debería incluirse en el pipeline.

Desarrollo completo / Solución esperada

(a) Orden correcto: **B** (estandarizar) $\rightarrow$ **D** (PCA sobre datos estandarizados) $\rightarrow$ **F** (clustering sobre representación PCA) $\rightarrow$ **G** (elegir k vía codo/Silhouette) $\rightarrow$ **H** (t-SNE/UMAP solo para visualización). En la práctica, G ocurre integrado con F (se prueban varios k antes de fijar el clustering final). Se acepta cualquier orden que respete: estandarización antes de PCA, PCA antes de clustering, y visualización (H) al final.

(b) Los 4 pasos incorrectos y por qué:

- **A** es incorrecto: PCA debe aplicarse después de estandarizar. De lo contrario, las variables de mayor escala dominarán artificialmente la varianza capturada por las componentes principales.
- **C** es incorrecto: clusterizar sobre una proyección 2D de UMAP distorsiona las distancias globales del espacio original (UMAP prioriza preservar vecindarios locales), pudiendo generar clusters artificiales.
- **E** es incorrecto: la inercia decrece monótonamente con k (mínimo trivial en $k = n$). Minimizarla sin más criterio lleva a sobreestimar sistemáticamente el número de clusters.
- **I** es incorrecto: t-SNE/UMAP son técnicas de visualización, no de clustering. No producen asignaciones de cluster por sí mismas ni deben reemplazar el paso de clustering.

Pregunta de Desarrollo 2

Un analista tiene un dataset de transacciones de e-commerce, sin ninguna etiqueta disponible. Se sospecha que existen “segmentos naturales” de comportamiento de compra (número desconocido), y que además existe una proporción pequeña pero real de transacciones fraudulentas o anómalas mezcladas en los datos.

- (a) ¿Qué algoritmo(s) de clustering de los vistos en el curso consideraría como candidatos principales para este escenario, dado que el número de segmentos es desconocido y existen probables outliers/fraude? Justifique explícitamente por qué estos algoritmos son más apropiados que otros vistos en el curso para este escenario particular.
- (b) Dado que no existe ground truth, ¿qué métrica(s) internas usaría para comparar distintas configuraciones de hiperparámetros (o distintos algoritmos candidatos) entre sí? Describa concretamente cómo la usaría (ej. qué compararía, qué buscaría maximizar o minimizar).
- (c) Proponga **una** forma práctica de validar, aunque sea parcialmente, que los clusters obtenidos son significativos en términos de negocio, pese a no contar con ground truth formal.

Desarrollo completo / Solución esperada

(a) Se espera DBSCAN y/o HDBSCAN como candidatos principales, justificando que no requieren definir k de antemano, a diferencia de K-Means y GMM, e identifican explícitamente puntos como outliers, lo cual es directamente relevante para el caso de transacciones anómalas, algo que K-Means y GMM no hacen de forma nativa. Se puede aceptar GMM como candidato secundario si se justifica el uso de probabilidades de pertenencia bajas como señal de anomalía, pero debe reconocerse su limitación de requerir K predefinido.

(b) Se espera mencionar el **Silhouette Score** (comparar su promedio entre distintas configuraciones de hiperparámetros, buscando maximizarlo) o el método del **Elbow**/gráfico **k-dist** (para elegir ε en DBSCAN). Debe describirse concretamente el procedimiento de comparación.

(c) Cualquier propuesta razonable, por ejemplo: revisar junto a expertos de negocio el perfil (valores promedio de las variables) de cada cluster para verificar que tengan sentido interpretable. Otra opción es verificar consistencia temporal (si los clusters se mantienen estables al re-ejecutar sobre distintos períodos de datos). O contrastar los clusters con alguna señal externa parcial disponible (ej. reportes de fraude confirmados manualmente, aunque sean pocos) como una forma de validación aproximada, no formal.