Material de Estudio I2

Minería de Datos (IIC-2433)

Maximiliano Ojeda

1 Selección Múltiple

Pregunta 1

La probabilidad condicional $P(A \mid B)$, con $P(B) > 0$, se define como:

A) $P(A, B) \,/\, P(A)$

B) $P(A, B) \,/\, P(B)$

C) $P(B \mid A)\, P(B) \,/\, P(A)$

D) $P(A)\, P(B) \,/\, P(A, B)$

Pregunta 2

Con $P(B) > 0$, los eventos A y B son independientes si y solo si:

A) $P(A \mid B) = P(A)$

B) $P(A \mid B) = P(B)$

C) $P(A \mid B) = P(B \mid A)$

D) $P(A \cap B) = 0$

Pregunta 3

En una red bayesiana, un arco $X \to Y$ indica que:

A) La CPT de Y está condicionada en el valor de X

B) La CPT de X está condicionada en el valor de Y

C) Y es independiente de X dado cualquier otra variable

D) X ocurre temporalmente después que Y

Pregunta 4

Un nodo binario X con dos padres binarios tiene una CPT con:

A) 2 entradas, una por cada valor de X

B) 3 distribuciones, una por cada variable involucrada

C) 8 distribuciones, una por combinación de las 3 variables

D) 4 distribuciones sobre X, una por combinación de padres

Pregunta 5

Respecto de Variable Elimination (VE) y Forward Sampling, es correcto afirmar que:

A) VE es aproximado y su error disminuye con más iteraciones

B) Ambos son exactos siempre que la red sea un DAG

C) VE es exacto, mientras que Forward Sampling aproxima con frecuencias

D) Forward Sampling es exacto si se muestrea en orden topológico

Pregunta 6

Al aproximar con forward sampling, ¿qué ocurre al pasar de 500 a 50.000 muestras?

A) La estimación tiende al valor exacto y su variabilidad disminuye

B) La estimación se vuelve exacta tras un número finito de muestras

C) La estimación converge a $P(I = \text{alta})$, pues la evidencia pierde peso

D) La estimación no cambia en promedio ni en variabilidad

Pregunta 7

El principio Apriori establece que:

A) Si un itemset es frecuente, todos sus superconjuntos lo son

B) Si un itemset es infrecuente, todos sus subconjuntos lo son

C) Si un itemset es frecuente, todas sus reglas superan la confianza mínima

D) Si un itemset es infrecuente, todos sus superconjuntos lo son

Pregunta 8

¿Qué supuesto de muchos modelos clásicos de ML deja de cumplirse en una serie de tiempo?

A) Que las variables sean numéricas

B) Que las observaciones sean i.i.d.

C) Que no existan valores faltantes

D) Que la variable objetivo sea continua

Pregunta 9

El test ADF sobre la serie diferenciada entrega $p = 0.0007$. Con $\alpha = 0.05$:

A) No se rechaza H_0: la serie diferenciada no es estacionaria

B) Se rechaza H_0: la serie diferenciada no es estacionaria

C) Se rechaza H_0: la serie diferenciada es estacionaria

D) No se rechaza H_0: la serie diferenciada es estacionaria

Pregunta 10

¿En qué caso es más apropiado aplicar logaritmo antes de modelar?

A) Cuando la variabilidad crece junto con el nivel

B) Cuando hay tendencia lineal y varianza constante

C) Cuando la serie toma valores negativos y positivos

D) Cuando la serie ya resultó estacionaria según ADF

Pregunta 11

En un ARIMA(2,1,3), el valor 1 indica:

A) Un término autorregresivo

B) Un término de media móvil

C) Una diferenciación de la serie

D) Un período estacional de la serie

Pregunta 12

Si se **aumenta** `min_support`, el número de itemsets frecuentes:

A) Disminuye o se mantiene, nunca aumenta

B) Aumenta o se mantiene, nunca disminuye

C) Puede aumentar o disminuir según el dataset

D) Disminuye solo si también se reduce la confianza mínima

Pregunta 13

Al aumentar el tamaño de la ventana de una media móvil, el resultado es:

A) Más suave y con menos atraso respecto de la serie

B) Menos suave y con más atraso respecto de la serie

C) Igual de suave, pero sin la tendencia de la serie

D) Más suave y con más atraso respecto de la serie

Pregunta 14

¿Por qué se dice que RMSE castiga más los errores grandes que MAE?

A) Porque eleva los errores al cuadrado antes de promediar

B) Porque divide cada error por el valor real antes de promediar

C) Porque toma la raíz de cada error antes de promediar

D) Porque usa el valor absoluto, evitando que los errores se cancelen

Pregunta 15

Del itemset frecuente {A,B,C,D}, la regla {B,C,D}→{A} no supera el umbral de confianza. ¿Cuál de las siguientes tampoco lo supera, con certeza?

A) {A,C,D}→{B}

B) {A,B,C}→{D}

C) {C,D}→{A,B}

D) {A,B}→{C,D}

Pregunta 16

ARIMA(2,1,1) tiene AIC = 952.3 y SARIMA(2,1,1)(1,1,1,12) tiene AIC = 247.2. ¿Qué precaución corresponde al compararlos?

A) Ninguna: el AIC siempre es comparable dentro de una misma serie

B) Ninguna: se elige ARIMA, pues un AIC mayor indica mejor ajuste

C) Con distinto D (0 vs 1), los AIC no son directamente comparables

D) No son comparables, porque SARIMA tiene más parámetros que ARIMA

Pregunta 17

Según lo visto en clases, ¿de dónde se obtienen típicamente p, d y q?

A) p: ACF · d: test ADF · q: PACF

B) p: PACF · d: test ADF · q: ACF

C) p: PACF · d: ACF · q: test ADF

D) p: test ADF · d: PACF · q: ACF

Pregunta 18

Si `min_support=0.2` con 20 transacciones. ¿En cuántas transacciones, como mínimo, debe aparecer un itemset para ser frecuente?

A) 2

B) 4

C) 5

D) 10

Pregunta	**Correcta**
Pregunta 1	B
Pregunta 2	A
Pregunta 3	A
Pregunta 4	D
Pregunta 5	C
Pregunta 6	A
Pregunta 7	D
Pregunta 8	B
Pregunta 9	C
Pregunta 10	A
Pregunta 11	C
Pregunta 12	A
Pregunta 13	D
Pregunta 14	A
Pregunta 15	C
Pregunta 16	C
Pregunta 17	B
Pregunta 18	B

2 Preguntas de Desarrollo

Pregunta de Desarrollo 1

(a) Para el AR(2) $y_t = 2 + 0.6\, y_{t-1} - 0.2\, y_{t-2} + \varepsilon_t$, con $y_t = 10$ e $y_{t-1} = 8$, calcule los pronósticos para $t+1$, $t+2$ y $t+3$.

(b) Para el MA(1) $y_t = 5 + \varepsilon_t + 0.5\, \varepsilon_{t-1}$, con último error estimado $\varepsilon_t = 2$, calcule los pronósticos para $t+1$, $t+2$ y $t+3$.

(c) Describa los patrones esperados de la ACF y la PACF para el AR(2) de (a) y el MA(1) de (b).

Nota: el pronóstico $\hat{y}_{t+h}$ corresponde al valor esperado de y_{t+h} dada la información disponible hasta t. Los errores futuros $(\varepsilon_{t+1}, \varepsilon_{t+2}, \dots)$ aún no se observan y son ruido blanco de media 0, por lo que se reemplazan por $E[\varepsilon] = 0$. Los errores pasados ya observados (como ε_t) sí se usan.

Desarrollo completo / Solución esperada

(a) $\hat{y}_{t+1} = 2 + 0.6 \cdot 10 - 0.2 \cdot 8 = 6.4$; $\hat{y}_{t+2} = 2 + 0.6 \cdot 6.4 - 0.2 \cdot 10 = 3.84$; $\hat{y}_{t+3} = 2 + 0.6 \cdot 3.84 - 0.2 \cdot 6.4 = 3.024$.
(b) $\hat{y}_{t+1} = 5 + 0.5 \cdot 2 = 6$; $\hat{y}_{t+2} = \hat{y}_{t+3} = 5$: tras $q = 1$ pasos, el pronóstico es la media.
(c) AR(2): ACF que decae gradualmente (puede oscilar) y PACF con corte después del rezago 2. MA(1): ACF con un único pico significativo en el rezago 1 y corte después; PACF que decae gradualmente.

Pregunta de Desarrollo 2

En la actividad de ventas minoristas mensuales de EE.UU. (1992–2016, test = últimos 24 meses) se obtuvieron los siguientes resultados *(datos ilustrativos)*:

Modelo	AIC	MAPE test
ARIMA(1,1,1)	4012	7.9 %
ARIMA(2,1,2)	3960	6.5 %
SARIMA(1,1,1)(1,1,1,12)	3420	1.9 %
SARIMA(2,1,2)(1,1,1,12)	3418	2.0 %
SARIMA(1,1,1)(1,1,1,4)	3880	8.4 %
SARIMA(1,1,1)(1,1,1,6)	3790	6.1 %

(a) ¿Qué característica de la serie explica la gran diferencia entre los ARIMA y los SARIMA con $s = 12$?

(b) SARIMA(2,1,2)(1,1,1,12) tiene un AIC levemente menor que SARIMA(1,1,1)(1,1,1,12), pero un MAPE levemente mayor. ¿Cuál elegiría? Justifique.

(c) Explique por qué $s = 4$ y $s = 6$ funcionan peor. ¿Es válido comparar directamente el AIC entre los SARIMA con $s = 4$, 6 y 12?

Desarrollo completo / Solución esperada

(a) La estacionalidad anual fuerte de las ventas (por ejemplo, el peak de diciembre). ARIMA no tiene términos estacionales: sus pronósticos se aplanan y no reproducen los peaks, lo que dispara el MAPE. SARIMA con $s = 12$ relaciona cada mes con el mismo mes del año anterior.
(b) SARIMA(1,1,1)(1,1,1,12). La diferencia de AIC (2 puntos) es mínima, y el modelo más grande tiene 2 parámetros más sin mejorar el error fuera de muestra. Por parsimonia y porque el MAPE en test mide directamente el desempeño de pronóstico, se prefiere el modelo simple.
(c) El período estacional real es 12: con $s = 4$ o $s = 6$ la diferencia estacional compara meses que no son equivalentes (por ejemplo, diciembre con junio), lo que no elimina el patrón anual y agrega ruido. El AIC no es estrictamente comparable: distintos s implican diferenciar con lags distintos (se pierden 4, 6 o 12 observaciones), así que la verosimilitud se calcula sobre series distintas; la comparación justa es el MAPE en el mismo test.

Pregunta de Desarrollo 3

En una tienda se registran $N = 1000$ transacciones: 200 incluyen Té, 800 incluyen Café y 150 incluyen ambos.

(a) Construya la tabla de contingencia 2×2 (Té / no Té $\times$ Café / no Café), con totales.

(b) Calcule la confianza y el lift de Té→Café. Compare con la proporción de clientes *sin* Té que compran Café. ¿Es Té→Café una buena regla?

(c) Se agregan al análisis 10.000 transacciones de otra sección de la tienda que no contienen ni Té ni Café. Recalcule el soporte, la confianza y el lift de Té→Café. ¿Qué métrica cambió y por qué?

(d) ¿Qué lección práctica deja (c) sobre cómo definir el conjunto de transacciones antes de aplicar Apriori?

Desarrollo completo / Solución esperada

(a)

	Café	No Café	Total
Té	150	50	200
No Té	650	150	800
Total	800	200	1000

(b) $c = 150/200 = 0.75$, lift $= 0.75/0.8 = 0.9375$. Entre quienes no compran Té, $650/800 = 0.8125$ compra Café: comprar Té *reduce* levemente la probabilidad de Café. No es una buena regla, pese a su confianza de 75 %.
(c) $N = 11{,}000$: $s = 150/11000 = 0.0136$ (antes 0.15) y $c = 150/200 = 0.75$ (sin cambio). lift $= \dfrac{150 \cdot 11000}{200 \cdot 800} \approx 10.3$ (antes 0.94). La confianza solo depende de transacciones con Té, así que no cambia. El soporte y el lift dependen de N: las transacciones nulas bajan s(Café) de 0.8 a 0.073 y hacen parecer que Té y Café están fuertemente asociados.
(d) El lift (y el soporte) dependen de qué transacciones se incluyen. Hay que definir un universo coherente con la pregunta de negocio (por ejemplo, solo boletas de la cafetería) y reportar soporte, confianza y lift juntos, no solo el lift.