

MINERÍA DE DATOS

Maximiliano Ojeda

muojeda@uc.cl



IIC-2433



T-SNE y UMAP

Stochastic Neighbor Embedding (SNE)


Objetivo

Proyectar datos en 2 o 3 dimensiones para visualización

Problema


Dados puntos de alta dimensión $\mathbf{x}_i \in \mathbb{R}^D (i = 1, \dots, n)$, t-SNE busca encontrar representaciones que conserven vecindades locales $\mathbf{y}_i \in \mathbb{R}^d$

Esto nos lleva al siguiente problema. Como hacer que dos distribuciones de similitud $\mathbf{P}$ (en alta dimensión) y $\mathbf{Q}$ (en baja dimensión) sean lo más parecidas posible



Stochastic Neighbor Embedding (SNE)



Visualización que **preserva distancias** del espacio original



SNE: Similitud en alta dimensión (P)

Para cada punto, definimos una distribución condicional sobre sus vecinos:

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)}, \quad \sigma_i \text{ es el ancho de la gaussiana del punto } i$$



SNE: Similitud en baja dimensión (Q)

Para cada punto, definimos una distribución condicional sobre sus vecinos:


$$q_{j|i} = \frac{\exp(-\|y_i - y_j\|^2)}{\sum_{k \neq i} \exp(-\|y_i - y_k\|^2)},$$

En baja dimensión no hay sigma, el embedding debe ser coherente en escala para todos los puntos → se fija un σ global

Divergencia KL (Kullback-Leibler)

Determina en qué medida una distribución de probabilidad se desvía de otra distribución de referencia

$$\text{KL}(P \parallel Q) = \sum_{x \in \mathcal{X}} P(x) \log \left(\frac{P(x)}{Q(x)} \right)$$



Divergencia KL en SNE

Determina en qué medida una distribución de probabilidad se desvía de otra distribución de referencia

$$\mathcal{C} = \sum_i \text{KL}(P_i \parallel Q_i) = \sum_i \sum_j p_{j|i} \log \left(\frac{p_{j|i}}{q_{j|i}} \right)$$

Debemos minimizar este “costo” de forma que la diferencia entre ambas distribuciones sea la menor posible.

t-SNE


t-SNE (2008, van der Maaten & Hinton) nace como una mejora directa de SNE. Dos diferencias claves:

- En baja dimensión cambia a una **t Student** con 1 grado de libertad

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq \ell} (1 + \|y_k - y_\ell\|^2)^{-1}}$$

- Define distribuciones simétricas

$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}$$



Model Complexity

Entropía: Mide la **incertidumbre promedio** o la cantidad de información esperada en una distribución de probabilidad.


$$H(P_i) = - \sum_j p_{j|i} \log_2 p_{j|i}$$

$$\text{Perp}(P_i) = 2^{H(P_i)}$$


- Se fija una perplejidad objetivo **Perp > 0** (típicamente 5–50)
- Se halla cada σ_i tal que $\text{Perp}(P_i) \approx$ la perplejidad objetivo.

```
tsne = TSNE(n_components=2, perplexity=30)  
X_embedded = tsne.fit_transform(X_scaled)
```

t-SNE



t-SNE 2 dimensiones MNIST




t-SNE 3 dimensiones MNIST

Uniform Manifold Approximation and Projection (UMAP)

Es un algoritmo de reducción de dimensionalidad parecido a t-SNE, pero con una teoría más sólida por debajo:

- **Supuesto de variedad:** los datos de alta dimensión X viven en una variedad (manifold) de dimensión mucho más baja dentro de $\mathbb{R}^D$.
- **Aproximación fuzzy-topológica:** la estructura de vecinos se representa con un grafo difuso (fuzzy graph) que codifica las relaciones de cercanía entre puntos.



Uniform Manifold Approximation and Projection (UMAP)

Diferencias con t-SNE:

- **Modelo teórico:** Se basa en geometría de variedades y topología algebraica
- **Estructura global:** Preserva mejor la forma global de los datos.
- **Parámetros clave:**
 - **n_neighbors:** vecinos considerados para aproximar métrica local
 - **min_dist:** separación entre puntos cercanos.

