

MINERÍA DE DATOS

Maximiliano Ojeda

muojeda@uc.cl



IIC-2433



En K-NN, el parámetro "k" representa:

- A) El número de veces que se debe repetir el algoritmo antes de converger.
- B) El número de vecinos más cercanos considerados.
- C) El número de componentes principales retenidas antes de clasificar un punto.
- D) El número de clusters que el algoritmo debe encontrar en el dataset.



En K-NN, el parámetro "k" representa:

- A) El número de veces que se debe repetir el algoritmo antes de converger.
- B) El número de vecinos más cercanos considerados.**
- C) El número de componentes principales retenidas antes de clasificar un punto.
- D) El número de clusters que el algoritmo debe encontrar en el dataset.



En K-NN para clasificación, la clase asignada a un nuevo punto se determina mediante:

- A) El promedio ponderado de las etiquetas numéricas de los k vecinos más cercanos.
- B) La clase del vecino ubicado exactamente en el centroide del conjunto de entrenamiento.
- C) La clase asignada al vecino con el valor de índice más bajo dentro del dataset.
- D) Votación por mayoría entre los k vecinos.



En K-NN para clasificación, la clase asignada a un nuevo punto se determina mediante:

- A) El promedio ponderado de las etiquetas numéricas de los k vecinos más cercanos.
- B) La clase del vecino ubicado exactamente en el centroide del conjunto de entrenamiento.
- C) La clase asignada al vecino con el valor de índice más bajo dentro del dataset.
- D) Votación por mayoría entre los k vecinos.**



En K-Means, ¿qué se hace en el paso de “Actualizar centroides”?

- A) Se eliminan los puntos que se encuentran más alejados del centroide anterior.
- B) Se calcula el promedio de los puntos en cada cluster y se mueve el centroide a esa posición.
- C) Se recalculan las distancias euclidianas entre todos los pares de puntos del dataset.
- D) Se selecciona aleatoriamente un nuevo punto del dataset como nuevo centroide.



En K-Means, ¿qué se hace en el paso de “Actualizar centroides”?

- A) Se eliminan los puntos que se encuentran más alejados del centroide anterior.
- B) Se calcula el promedio de los puntos en cada cluster y se mueve el centroide a esa posición.**
- C) Se recalculan las distancias euclidianas entre todos los pares de puntos del dataset.
- D) Se selecciona aleatoriamente un nuevo punto del dataset como nuevo centroide.



En DBSCAN, el parámetro eps representa:

- A) El radio de vecindad generado en torno a cada punto.
- B) El número mínimo de puntos para formar un cluster.
- C) El número de clusters que el algoritmo debe encontrar en el dataset.
- D) La distancia máxima permitida entre un punto y el centroide de su cluster.



En DBSCAN, el parámetro eps representa:

- A) El radio de vecindad generado en torno a cada punto.**
- B) El número mínimo de puntos para formar un cluster.
- C) El número de clusters que el algoritmo debe encontrar en el dataset.
- D) La distancia máxima permitida entre un punto y el centroide de su cluster.



Un investigador tiene dos vectores de conteo de palabras de documentos de distinta extensión (uno muy largo, otro muy corto) y quiere comparar su orientación temática sin que la longitud del documento afecte la comparación. La métrica más apropiada es:

- A) Distancia Euclidiana
- B) Distancia Manhattan
- C) Similitud Coseno
- D) Distancia de Hamming



Un investigador tiene dos vectores de conteo de palabras de documentos de distinta extensión (uno muy largo, otro muy corto) y quiere comparar su orientación temática sin que la longitud del documento afecte la comparación. La métrica más apropiada es:

- A) Distancia Euclidiana
- B) Distancia Manhattan
- C) Similitud Coseno**
- D) Distancia de Hamming



En el proceso de PCA, ¿por qué es necesario centrar los datos (restar la media) antes de calcular la matriz de covarianza?

- A) Porque de lo contrario los autovalores obtenidos serían siempre números complejos.
- B) Porque PCA solo puede aplicarse a datos previamente normalizados al rango $[0,1]$.
- C) Porque de lo contrario no sería posible aplicar la descomposición SVD sobre la matriz de datos.
- D) Porque la matriz de covarianza asume datos centrados en el origen para medir correctamente la varianza.



En el proceso de PCA, ¿por qué es necesario centrar los datos (restar la media) antes de calcular la matriz de covarianza?

- A) Porque de lo contrario los autovalores obtenidos serían siempre números complejos.
- B) Porque PCA solo puede aplicarse a datos previamente normalizados al rango $[0,1]$.
- C) Porque de lo contrario no sería posible aplicar la descomposición SVD sobre la matriz de datos.
- D) Porque la matriz de covarianza asume datos centrados en el origen para medir correctamente la varianza.**



En el método del codo (Elbow), a medida que aumenta k , la inercia:

- A) Disminuye (o se mantiene igual), ya que más clusters reducen el error dentro de cada grupo.
- B) Aumenta de forma constante, ya que agregar más clusters añade más términos a la suma total.
- C) Permanece exactamente constante, sin importar cuántos clusters adicionales se agreguen.
- D) Fluctúa de manera impredecible, sin ninguna relación clara con el valor de k .



En el método del codo (Elbow), a medida que aumenta k , la inercia:

- A) Disminuye (o se mantiene igual), ya que más clusters reducen el error dentro de cada grupo.**
- B) Aumenta de forma constante, ya que agregar más clusters añade más términos a la suma total.
- C) Permanece exactamente constante, sin importar cuántos clusters adicionales se agreguen.
- D) Fluctúa de manera impredecible, sin ninguna relación clara con el valor de k .



Un dataset contiene un cluster muy denso de 1000 puntos y un cluster disperso de solo 5 puntos, muy alejado del primero. Al aplicar K-Means con $k = 2$ con inicialización desafortunada, es posible que uno de los centroides iniciales caiga muy cerca de un outlier extremo del cluster grande. Explique el efecto más probable en la convergencia final

- A) K-Means detectará automáticamente el outlier y lo excluirá del cálculo de los centroides finales.
- B) El algoritmo convergerá igualmente al resultado óptimo global, sin importar la inicialización de los centroides.
- C) El centroide puede quedar atrapado representando una partición no deseada del cluster grande.
- D) El cluster disperso de 5 puntos será fusionado automáticamente dentro del cluster denso, sin afectar la calidad del resultado.



Un dataset contiene un cluster muy denso de 1000 puntos y un cluster disperso de solo 5 puntos, muy alejado del primero. Al aplicar K-Means con $k = 2$ con inicialización desafortunada, es posible que uno de los centroides iniciales caiga muy cerca de un outlier extremo del cluster grande. Explique el efecto más probable en la convergencia final

- A) K-Means detectará automáticamente el outlier y lo excluirá del cálculo de los centroides finales.
- B) El algoritmo convergerá igualmente al resultado óptimo global, sin importar la inicialización de los centroides.
- C) El centroide puede quedar atrapado representando una partición no deseada del cluster grande.**
- D) El cluster disperso de 5 puntos será fusionado automáticamente dentro del cluster denso, sin afectar la calidad del resultado.

Complete la siguiente tabla comparando K-Means, DBSCAN, GMM y HDBSCAN según los cuatro criterios indicados (2 puntos por fila, evaluando la fila completa)

Criterio	K-Means	DBSCAN	GMM	HDBSCAN
¿Requiere definir el número de clusters k de antemano?				
¿Asume una forma geométrica particular de los clusters?				
¿Asignación dura (hard) o suave (soft)?				
¿Identifica explícitamente outliers/ruido?				



Un colega le escribe: “Calculé el Silhouette Score de mi clustering usando las etiquetas reales del dataset (el ground truth) en vez de las asignaciones que entregó mi algoritmo, y obtuve 0.85. Como el valor es tan alto y cercano a 1, concluyo que mi modelo de clustering es excelente y recupera muy bien las clases reales.”

(a) Explique con precisión qué mide realmente el Silhouette Score (en términos de $a(i)$ y $b(i)$), señalando explícitamente que NO utiliza ni compara contra ninguna etiqueta “real” externa en su definición.

(b) Señale el error conceptual específico de su colega.

(c) Indique cuál es la métrica correcta que su colega debería haber usado para comparar el resultado de su algoritmo de clustering contra el ground truth, y explique brevemente en qué se diferencia de Silhouette.

Un colega le escribe: “Calculé el Silhouette Score de mi clustering usando las etiquetas reales del dataset (el ground truth) en vez de las asignaciones que entregó mi algoritmo, y obtuve 0.85. Como el valor es tan alto y cercano a 1, concluyo que mi modelo de clustering es excelente y recupera muy bien las clases reales.”

- (a) Debe explicitar $s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$, donde $a(i)$ es la distancia promedio de un punto a los demás puntos de su mismo cluster (cohesión) y $b(i)$ la distancia promedio al cluster vecino más cercano (separación); es una métrica puramente **interna**, calculada solo a partir de distancias entre puntos y sus asignaciones a grupos, sin ninguna referencia a un ground truth externo.
- (b) Debe señalar que un Silhouette=0.85 calculado sobre las etiquetas reales solo confirma que esas clases reales están bien separadas geométricamente en el espacio de atributos usado (lo cual es una propiedad del dataset, no del algoritmo), pero **no dice nada** sobre si el clustering que produjo el algoritmo del colega coincide con esas etiquetas reales; el colega parece haber confundido “evaluar la separabilidad del ground truth” con “evaluar la calidad de su propio clustering”.
- (c) Debe indicar el **Adjusted Rand Index (ARI)**, explicando que a diferencia de Silhouette, el ARI sí compara explícitamente dos particiones (la del algoritmo del colega vs. el ground truth), midiendo cuántos pares de puntos coinciden en estar juntos o separados en ambas particiones, corregido por el nivel de coincidencia esperado bajo asignación aleatoria.

MINERÍA DE DATOS

Maximiliano Ojeda

muojeda@uc.cl



IIC-2433